

# *Processamento Vectorial*

Arquitetura de Computadores  
Licenciatura em Engenharia Informática  
Luís Paulo Santos

# Material de Apoio

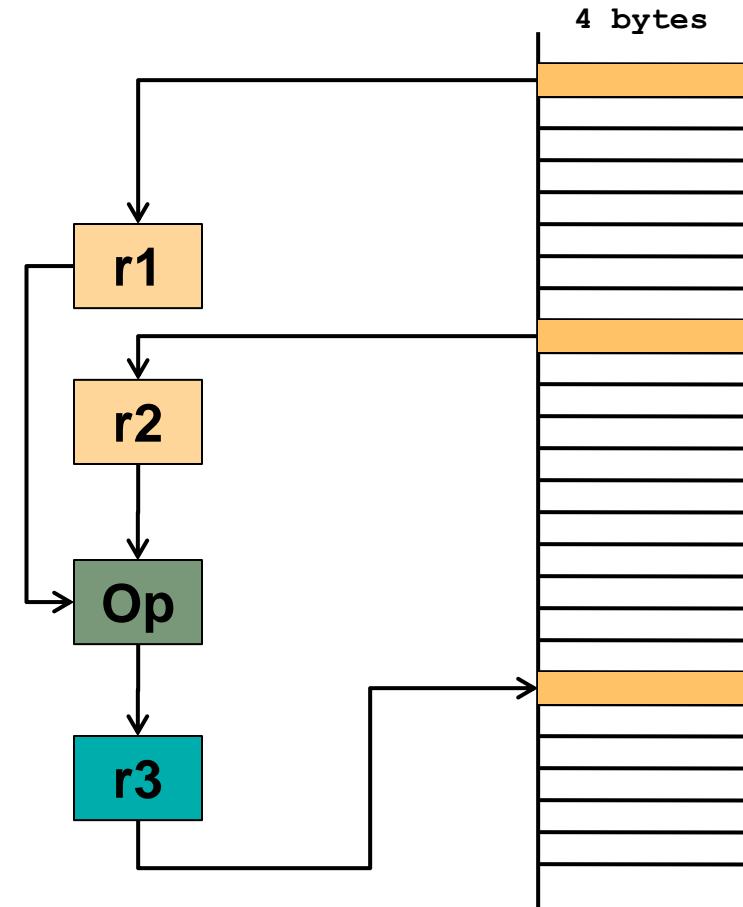
- “*Computer Systems: a Programmer's Perspective*”; Randal E. Bryant, David R. O'Hallaron--Pearson (3rd ed., 2016)  
Web aside: <http://csapp.cs.cmu.edu/3e/waside/waside SIMD.pdf>
- “*Computer Organization and Design: The Hardware / Software Interface*”  
David A. Patterson, John L. Hennessy; 5th Edition, 2013
  - Secções 3.7 e 3.8 (págs. 224 a 228)
  - Secção 6.3 (págs. 509 a 515) – SISD, MIMD, SIMD, SPMD and Vector

# Processamento Escalar

Cada instrução processa apenas **um** elemento do conjunto de dados

```
for (i=0 ; i < SIZE ; i++) {  
    c[i] = a[i] + b[i];  
}
```

```
loop:  
    movl (%esi, %ecx, 4), %eax  
    movl (%edi, %ecx, 4), %edx  
    addl %eax, %edx  
    movl %edx, (%ebx, %ecx, 4)  
    incl %ecx  
    cmpl SIZE, %ecx  
    jl loop
```



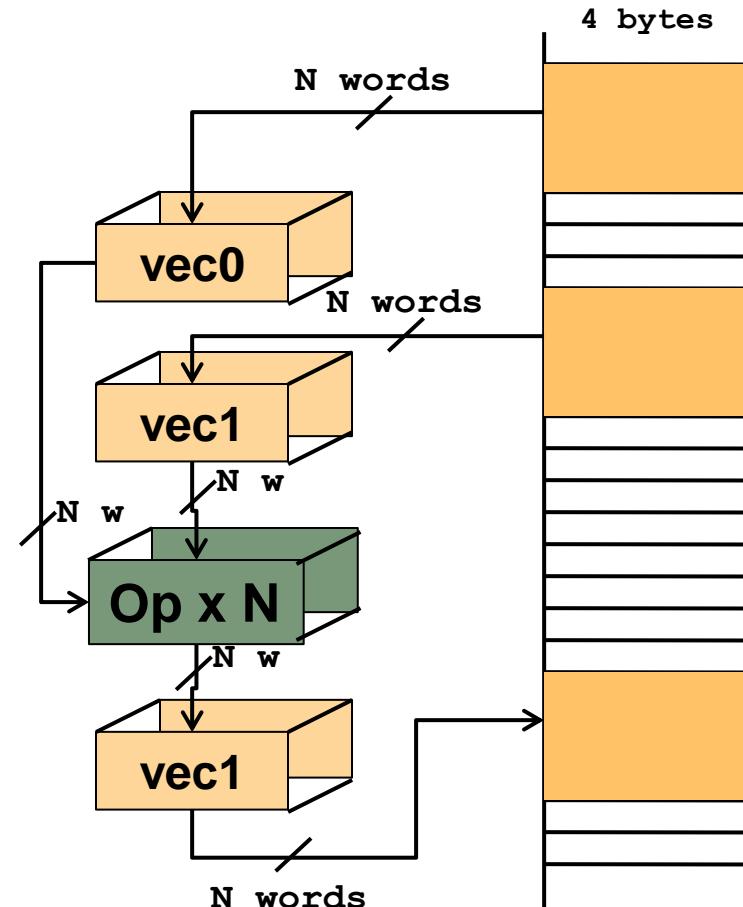
# Processamento Vectorial

## DATA LEVEL PARALLELISM

Cada instrução processa **N** elementos do conjunto de dados

```
for (i=0 ; i < SIZE ; i++) {  
    c[i] = a[i] + b[i];  
}
```

```
loop:  
    mov.v (%esi, %ecx, 4), %vec0  
    mov.v (%edi, %ecx, 4), %vec1  
    add.v %vec0, %vec1  
    mov.v %vec1, (%ebx, %ecx, 4)  
    addl $N, %ecx  
    cmpl SIZE, %ecx  
    jl loop
```

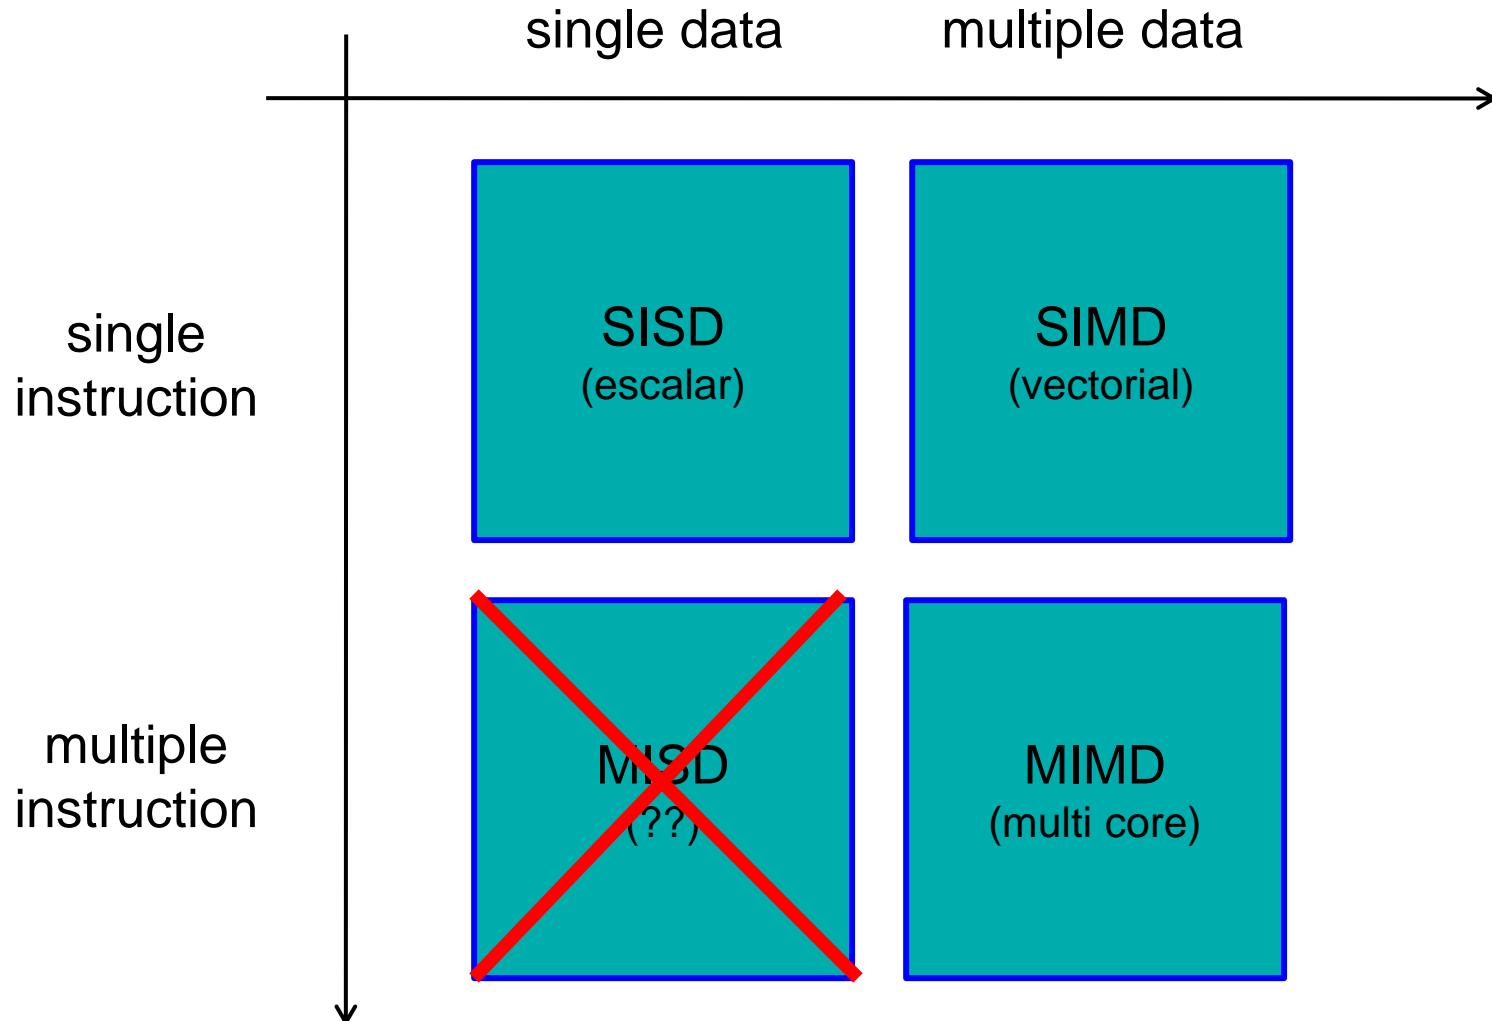


# Processamento Vectorial

$$T_{EXEC} = CPI * \#I / f$$

- **#I** – reduz, cada instrução processa **N** elementos de dados
- **CPI**
  - as unidades funcionais vectoriais realizam as **N** operações em paralelo, contribuindo para **manter o CPI**
  - **mas** a quantidade de dados a transferir de e para a memória por unidade de tempo (por instrução / ciclo do relógio) aumenta, contribuindo para **aumentar o CPI**

# Paralelismo – Taxonomia de Flynn



# *Intel SSE*

1994 – Pentium II e Pentium with MMX – MultiMedia eXtensions

8 registos de 64 bits (%mm0 .. %mm7) que mapeiam nos registos de vírgula flutuante (%st0 .. %st7) ; apenas operações sobre inteiros

1995 – Introdução de Streaming Simd Extensions (SSE) no Pentium III

8 novos registos de 128 bits (%xmm0 .. %xmm7) e operações FP

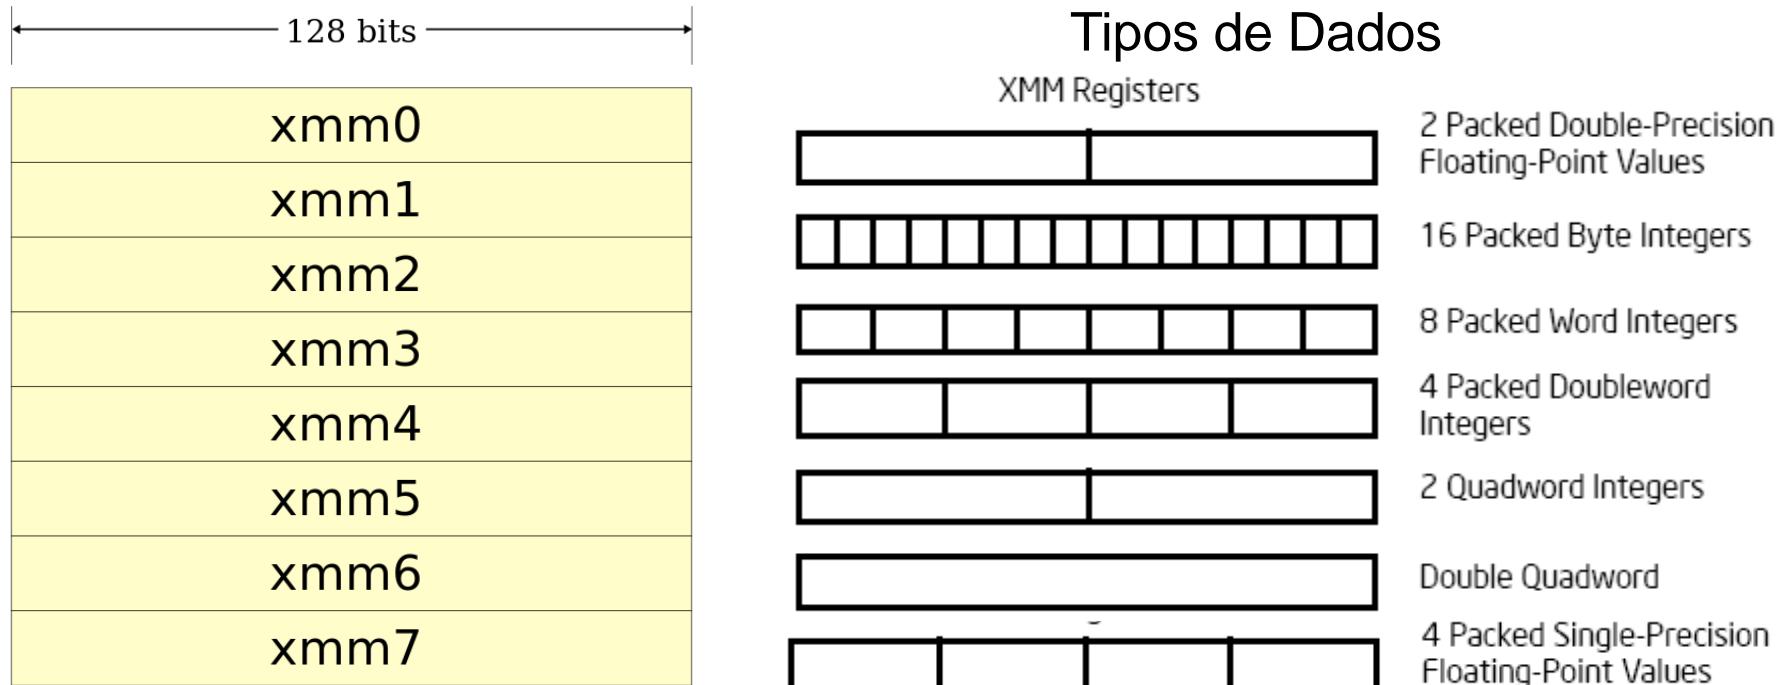
2000 – Introdução de SSE2 no Pentium IV

2004 - Introdução de SSE3 no Pentium IV HT

2007 - Introdução de SSE4

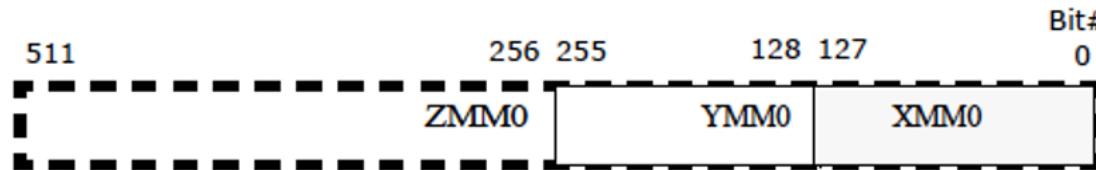
# Intel SSE - Streaming SIMD Extensions

- SSE adiciona à arquitectura Intel 8 registos de 128 bits: `%xmm0` .. `%xmm7`
- adiciona ainda instruções para operar sobre vectores de vários tipos de dados



# Intel Advanced Vector Extensions (AVX)

- Intel AVX – 16 registros YMM0 .. YMM15 de 256 bits  
*incluindo todas as operações e tipos de dados SSE, referido como AVX128 (Sandy Bridge, 2011)*
- Intel AVX2 – suporte para inteiros e *Fused-Multiply-Add (FMA)* (Haswell, 2013)
- Intel AVX512 – 32 registros ZMM0 .. ZMM31 de 512 bits  
*(Knights Landing, Xeon Phi, June, 2016; Intel Xeon Skylake)*



YMMx : 8 SPFP (ou 8 int se AVX2)

SPFP7	SPFP6	SPFP5	SPFP4	SPFP3	SPFP2	SPFP1	SPFP0
-------	-------	-------	-------	-------	-------	-------	-------

YMMx : 4 DPFP

DPFP3	DPFP2	DPFP1	DPFP0
-------	-------	-------	-------

# Instruções AVX: Notação

- O AVX introduz a notação de 3 operandos, previamente inexistente no x86:
  - 0 operandos: ADD - operandos no topo da stack
  - 1 operando: ADD <op1> - usa implicitamente um registo: o acumulador
  - 2 operandos: ADD <op1>, <op2> - x86:  $<\text{op2}> = <\text{op2}> + <\text{op1}>$
  - 3 operandos: ADD <op1>, <op2>, <op3> - RISC, AVX:  $<\text{op3}> = <\text{op2}> + <\text{op1}>$
- A operação de adição (`ADD`) é usada como exemplo
- `%xmm?` registo de 128 bits, `%ymm?` registo de 256 bits, `%zmm?` registo de 512 bits
- `m128`, `m256`, `m512` referem operandos em memória: 128, 256 e 512 bits
- Instruções AVX com o prefixo `V` usam o formato de três operandos:
  - `VADDPS %[x|y|z]mm?, %[x|y|z]mm? / m[128|256|512], %[x|y|z]mm?`
    - adiciona os 2 operandos da esquerda guarda o resultado no operando da **DIREITA**

# Instruções AVX: Notação

- Instruções com o sufixo **S** operam sobre valores em vírgula flutuante precisão simples; o sufixo **D** indica vírgula flutuante precisão dupla:
  - VADDPS %ymm?, %ymm? / m256, %ymm? – realiza **8** operações em **SPFP**
  - VADDPD %ymm?, %ymm? / m256, %ymm? – realiza **4** operações em **DPFP**
- Muitas instruções admitem a forma escalar, isto é, apenas realizam **UMA** operação sobre o valor armazenado nos *bits* menos significativos dos operandos. O penúltimo carácter pode tomar os valores **S** ou **P**, para indicar operação escalar (**UMA ÚNICA OPERAÇÃO**) ou vectorial, respectivamente:
  - VADDPS %ymm?, %ymm? / m256, %ymm? – realiza **8** operações em SPFP
  - VADDPD %ymm?, %ymm? / m256, %ymm? – realiza **4** operações em DPFP
  - VADDSS %ymm?, %ymm? / m256, %ymm? – realiza **1** operação em SPFP
  - VADDSD %ymm?, %ymm? / m256, %ymm? – realiza **1** operação em DPFP

Esta notação permite substituir o conjunto de instruções de vírgula flutuante classico do x86, orientado a uma stack de 8 registos, por uma alternativa mais flexível

# Instruções AVX: Transferência de Dados

- **VMOV [A | U] P [S | D]**

Mover vectores, representando valores SPFP ou DPFP (sufixo S ou D), de endereços alinhados ou não (modificador A ou U)

- VMOVUPD m256, %ymm? – move 4 DPFP de memória (endereço não alinhado) para %ymm?
- VMOVAPD %xmm?, m128 – move 2 DPFP de %xmm? para memória (endereço alinhado)

- **Alinhamento:** um bloco de dados com **B bytes**, diz-se alinhado, se o endereço inicial desse bloco em memória é múltiplo de **B**.
- Acessos alinhados são **significativamente** mais eficazes do que acessos não alinhados.
- AVX2 permite o uso de instruções A (*aligned*) com acessos não alinhados, com penalização no desempenho. SSE e AVX resulta numa excepção.

# Instruções AVX: Operações FP

Instruções	Operandos
VADD [S   P] [S   D]	
VSUB [S   P] [S   D]	[S   P] : escalar ou vectorial ?
VMUL [S   P] [S   D]	
VDIV [S   P] [S   D]	[S   D] : SPFP ou DPFP ?
VSQRT [S   P] [S   D]	
VMAX [S   P] [S   D]	Endereços em memória alinhados
VMIN [S   P] [S   D]	
VAND [S   P] [S   D]	O resultado não pode ser em memória
VOR [S   P] [S   D]	
...	

```

float a[1000] __attribute__ ((aligned(32)));
float b[1000] __attribute__ ((aligned(32)));
float r[1000] __attribute__ ((aligned(32)));

func (int n, float __restrict__ *a,
      float __restrict__ *b, float
      __restrict__ *r) {
    int i;
    for (i=0 ; i<n ; i++)
        r[i] = a[i] * b[i];
}

```

## Exemplo AVX

```

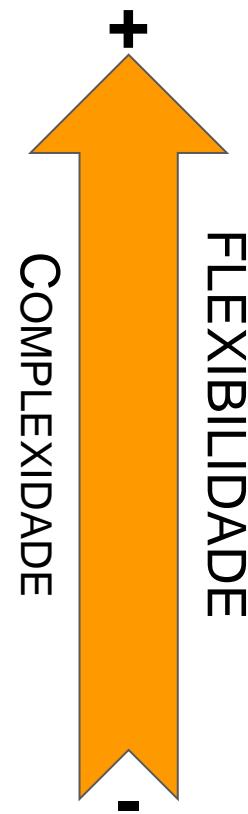
func:
    ...
    movl 8(%rbp), %rdx      # n
    movl 12(%rbp), %rax      # a
    movl 16(%rbp), %rbx      # b
    movl 20(%rbp), %rsi      # r
    movl $0, %rcx

ciclo:
    vmovaps (%rax, %rcx, 4), %ymm0
    vmulps (%rbx, %rcx, 4), %ymm0, %ymml1
    vmovaps %ymml1, (%rsi, %rcx, 4)
    addl $8, %rcx
    cmpl %rdx, %rcx
    jl ciclo
    ...

```

# Processamento Vectorial - desenvolvimento

- *Assembly*
  - Utilização directa de instruções *assembly*
- *Compiler Intrinsics*
  - Pseudo-funções disponibilizadas pelo compilador que permitem o desenvolvimento explícito de código vectorial a um nível semântico mais elevado que o *assembly*
- *Auto Vectorização*
  - Vectorização pelo compilador



# *Compiler Intrinsics*

- *Compiler intrinsics* são pseudo-funções que expõem funcionalidades do CPU incompatíveis com a semântica da linguagem de programação usada (C/C++ neste caso)

Para detalhes ver [Intel Intrinsics Guide](https://software.intel.com/sites/landingpage/IntrinsicsGuide/#) (<https://software.intel.com/sites/landingpage/IntrinsicsGuide/#>)

# *Compiler Intrinsics*

- As funções e tipos de dados definidos como *intrinsics* são acessíveis incluindo os *headers* apropriados:

xmmmintrin.h	Streaming SIMD Extensions	SSE
emmmintrin.h	Streaming SIMD Extensions 2	SSE2
pmmmintrin.h	Streaming SIMD Extensions 3	SSE3
smmmintrin.h	Streaming SIMD Extensions 4 (vector math)	SSE4.1
nmmmintrin.h	Streaming SIMD Extensions 4 (string processing)	SSE4.2
immmintrin.h	Advanced Vector Extensions 1 e 2	AVX2

Tipos de Dados	
<code>__m64</code>	Vector de 64 bits – inteiros (MMX)
<code>__m128</code>	Vector 128 <i>bits</i> – 4 FP SP (SSE)
<code>__m256</code>	Vector 256 <i>bits</i> – 8 FP SP (AVX)

# *Compiler Intrinsics*

Operações Aritméticas (single FP)		
Pseudo-função	Descrição	Instrução
<code>__m256 __mm_add_ps (__m256, __m256)</code>	Adição	VADDPS
<code>__m256 __mm_sub_ps (__m256, __m256)</code>	Subtracção	VSUBPS
<code>__m256 __mm_mul_ps (__m256, __m256)</code>	Multiplicação	VMULPS
<code>__m256 __mm_div_ps (__m256, __m256)</code>	Divisão	VDIVPS
<code>__m256 __mm_sqrt_ps (__m256)</code>	Raiz Quadrada	VSQRTPS
<code>__m256 __mm_rcp_ps (__m256)</code>	Inverso	VRCPPS
<code>__m256 __mm_rsqrt_ps (__m256)</code>	Inverso Raiz Quadrada	VRSQRTPS

# *Compiler Intrinsics*

Movimento de Dados (single FP)		
Pseudo-função	Descrição	Instrução
<code>__m256 __mm256_load_ps (float *)</code>	Carrega vector de memória para registo (alinhado 32)	VMOVAPS
<code>__m256 __mm_broadcast_ps (float *)</code>	Carrega 1 FP de memória para os 8 elementos do registo YMM	VBROADCA STSS
<code>_mm256_store_ps (float *, __m256)</code>	Escreve registo em vector de memória (alinhado 32)	VMOVAPS
<code>__m256 __mm256_set1_ps (float)</code>	Todos os 8 elementos do registo YMM são iniciados com o mesmo float	---

# *Compiler Intrinsics: Exemplo 1*

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

func() {
    for (int i=0 ; i< SIZE ; i++) {
        c[i] = a[i] + b[i];
    }
}
```

```
#include <immintrin.h>
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

func() {
    for (int i=0 ; i<SIZE ; i+=8) {
        __m256 mb = _mm256_load_ps (&b[i]);
        __m256 ma = _mm256_load_ps(&a[i]);
        __m256 mc = _mm256_add_ps (ma, mb);
        _mm256_store_ps (&c[i], mc);
    }
}
```

# *Compiler Intrinsics: Exemplo 2*

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

float alfa;

func() {
    for (int i=0 ; i<SIZE ; i++)
        c[i] = alfa * a[i];
}
```

```
#include <immintrin.h>
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));
float alfa;
func() {
    __m256 m_alfa = _mm256_broadcast_ps (&alfa);
    for (int i=0 ; i<SIZE ; i+=8) {
        __m256 mb = _mm256_load_ps (&b[i]);
        __m256 ma = _mm256_load_ps (&a[i]);
        ma = _mm256_mul_ps (ma, m_alfa);
        __m256 mc = _mm256_add_ps (ma, mb);
        _mm256_store_ps (&c[i], mc);
    }
}
```

# *Compiler Intrinsics: Exemplo 3*

```
#include <math.h>
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

func() {
    for (int i=0 ; i< SIZE ; i++) {
        #include <ia32intrin.h>
    } } #define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

func() {
    __m256 cinco = _mm256_set1_ps (5.);
    for (int i=0 ; i<SIZE ; i+=8) {
        __m256 mb = _mm256_sqrt_ps(_mm256_load_ps (&b[i]));
        __m256 ma = _mm256_load_ps(&a[i]);
        __m256 mr = _mm256_mul_ps (cinco, _mm256_add_ps (ma, mb));
        _mm256_store_ps (&c[i], mr);
    } }
```

# Auto-vectorização

- O compilador pode vectorizar o código
- Comando gcc:

gcc -O3 -march=...

Ou

gcc -ftree-vectorize -march=....

# Auto-vectorização

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        c[i] = a[i] + b[i];
    }
}
```

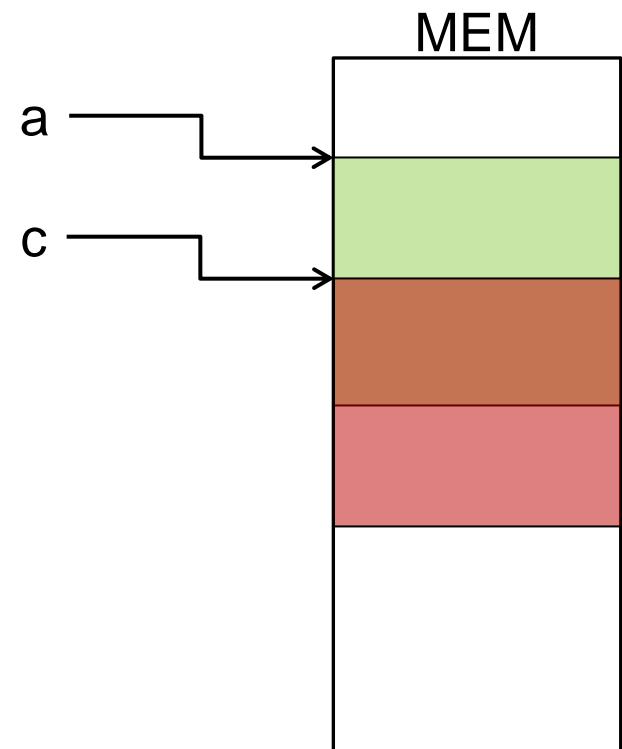
```
loop:
    xor %eax, %eax
.L1:
    vmovaps a(%eax), %ymm0
    vaddps b(%eax), %ymm0, %ymm0
    vmovaps %ymm0, c(%eax)
    add $32, %eax
    cmp $4000000, %eax
    jl .L1
    ret
```

# Auto-vectorização

```
loop (float *a, float *b, float *c, const int S) {  
    for (int i=0 ; i< S ; i++) {  
        c[i] = a[i] + b[i];  
    } }
```

Possibilidade de **aliasing**, isto é:  
as regiões de memória apontadas  
pelos diferentes apontadores podem-  
se sobrepor!

**versioning**, isto é:  
O compilador gera versões escalares e  
vectoriais do ciclo e código para  
verificar o **aliasing**.  
Em *runtime* é escolhida a versão mais  
apropriada do ciclo



# Auto-vectorização

```
loop ( float * __restrict__ a, float * __restrict__ b,
       float * __restrict__ c, const int S) {
    for (int i=0 ; i< S ; i++) {
        c[i] = a[i] + b[i];
    }
```

O qualificador `__restrict__` indica ao compilador que durante a existência daquele apontador

**NÂO EXISTE QUALQUER OUTRA REFERÊNCIA**  
para a zona de memória acedida a partir desse apontador.  
Logo não existe a possibilidade de *aliasing*

# Bloqueadores Auto-vectorização: dados não contíguos

```
#define SIZE 1000000
typedef struct {float a, b, c, pad;} MYDATA;

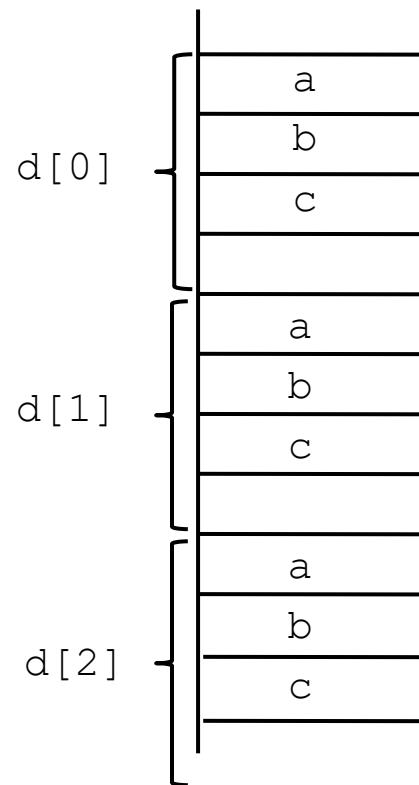
MYDATA d[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        d[i].c = d[i].a + d[i].b;
    }
}
```

Array of Structures (AoS) :

os vários elementos do mesmo campo não  
são armazenados consecutivamente em  
memória.

Código não vectorizável!



# Bloqueadores Auto-vectorização: dados não contíguos

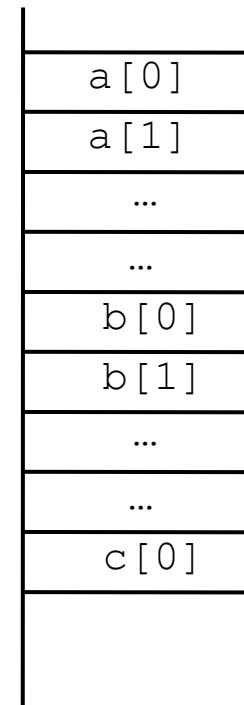
```
#define SIZE 1000000
struct {
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));
} d;

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        d.c[i] = d.a[i] + d.b[i];
    }
}
```

Structures of Arrays (SoA) :

os vários elementos do mesmo campo são  
armazenados consecutivamente em  
memória.

Código vectorizável!



# Bloqueadores Auto-vectorização: dados contíguos

```
#define SIZE 1000000
struct {
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));
} d;

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        d.c[i] = d.a[i] + d.b[i];
    }
}
```

```
loop:
    xor %eax, %eax
.L1:
    vmovaps d(%eax), %ymm0
    vaddps d+4000000(%eax), %ymm0
    vmovaps %ymm0, d+8000000(%eax)
    add $32, %eax
    cmp $4000000, %eax
    jl .L1
    ret
```

# AoS versus SoA

- o mapeamento das estruturas de dados como AoS é mais natural para o programador e resulta em código mais legível
- a utilização de SoA resulta numa melhor utilização da memória (menos *padding*), maior localidade especial e permite vectorização

Alguma linguagens de programação recentes permitem indicar ao compilador qual o mapeamento desejado sem alterar a indexação da informação a tratar:  
**ODIN** (<https://odin-lang.org/docs/overview/#soa-data-types>)

```
Vector3 :: struct {x, y, z: f32}
N :: 2

v_aos: [N]Vector3
v_aos[0].x = 1 v_aos[0].y = 4
v_aos[0].z = 9
v_aos[1] = {0, 3, 4}
fmt.println(v_aos)
```

```
// Same syntax as AOS
// treat as if it was an array

v_soa: #soa[N]Vector3
v_soa[0].x = 1 v_soa[0].y = 4
v_soa[0].z = 9
v_soa[1] = {0, 3, 4}
fmt.println(v_soa)
```

# Bloqueadores Auto-vectorização: *stride*

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
loop () {
    for (int i=0 ; i< SIZE ; i+=2) {
        a[i] = a[i] + 1;
    }
}
```

*Stride != 1*

Acessos **não contíguos**, mas **ordenados**.

Compilador pode não vectorizar o código.

Código (mesmo vectorial) menos eficiente, devido a acessos a memória e reduzida localidade espacial.

# Bloqueadores Auto-vectorização: *uncountable loops*

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; a[i]!=0 && i< SIZE ; i++) {
        c[i] = a[i] + b[i];
    }
}
```

O número de iterações não pode ser computado  
(*uncountable loop*):  
Código não vectorizável!

# Bloqueadores Auto-vectorização: condições

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        float s = a[i] + b[i];
        if (s<0.) {c[i] = s;}
        else if (s==0.) {c[i] = -10.;}
        else {c[i] = -s;}
    }
}
```

Estruturas condicionais:  
Código não vectorizável!

# Bloqueadores Auto-vectorização: condições

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        float s = a[i] + b[i];
        c[i] = (s < 0 ? s : 0);
    }
}
```

Algumas estruturas condicionais simples realizáveis como uma máscara: Código vectorizável nesses casos

## NOTA:

s é calculado para todos os elementos do vector.  
usando uma máscara só é atribuído aqueles elementos de c para os quais s é <0!

# Bloqueadores Auto-vectorização: funções

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        c[i] = myfunc(a[i]) + b[i];
    }
}
```

Invocação de funções dentro do ciclo:  
Código não vectorizável!

# Bloqueadores Auto-vectorização: funções

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
float b[SIZE] __attribute__ ((aligned(32)));
float c[SIZE] __attribute__ ((aligned(32)));

loop () {
    for (int i=0 ; i< SIZE ; i++) {
        c[i] = __builtin_absf(a[i]) + b[i];
    }
}
```

Invocação de funções intrínseca dentro do ciclo:  
Código vectorizável!

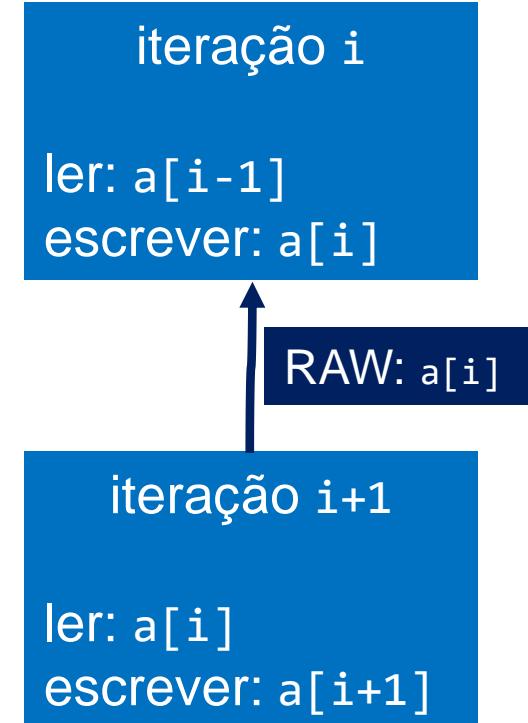
# Bloqueadores Auto-vectorização: dependências

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
loop () {
    for (int i=1 ; i< SIZE ; i++) {
        a[i] = a[i-1] + 1;
    }
}
```

Dependência *read after write* (RaW)!

Como  $i$  cresce, o valor de  $a[i+1]$  é alterado na próxima iteração anterior!

Código não vectorizável!



# Bloqueadores Auto-vectorização: dependências

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
loop () {
    for (int i=0 ; i< SIZE-1 ; i++) {
        a[i] = a[i+1] + 1;
    }
}
```

Dependência write *after read* (*WaR*)!

Como  $i$  cresce, o valor de  $a[i+1]$  só será alterado na próxima iteração!

Código vectorizável!

$$a[0] = a[1]+1;$$

$$a[1] = a[2]+1;$$

$$a[2] = a[3]+1;$$

$$a[3] = a[4]+1;$$

# Bloqueadores Auto-vectorização: dependências

- Distância da dependência : diferença entre o índice de escrita e o índice de leitura

$$d = c^W - c^R$$

- Se  $d \leq 0$  não há dependências RaW : ciclo pode ser vectorizado

<pre>for (i=1 ; i &lt; SIZE ; i++) {     a[i] = 2 * a[i-1]; }</pre>	<pre>for (i=0 ; i &lt; SIZE-1 ; i++) {     a[i] = 2 * a[i+1]; }</pre>
$d = i - (i-1) = 1$ $d > 0 \Rightarrow \text{RaW}$	$d = i - (i+1) = -1$ $d < 0 \Rightarrow \text{WaR}$

- Nota: o sinal da distância deve respeitar a ordem de iteração.  
Isto é, se o índice for decrementado então  $d = -(c^W - c^R)$

# Bloqueadores Auto-vectorização: dependências

```
#define SIZE 1000000
float a[SIZE]
__attribute__((aligned(32)));
loop () { float c;
    for (int i=1 ; i< SIZE ; i++) {
        c = a[i-1]*2 ;
        a[i] = (c >0 ? c : 1);
    }
}
```

$$d = c^W - c^R = i - (i - 1) = 1$$

```
a[1] = a[0]*2 : 1;
a[2] = a[1]*2 : 1;
```

*read after write*

Código NÃO vectorizável!

```
#define SIZE 1000000
float a[SIZE]
__attribute__((aligned(16)));
loop () { float c;
    for (int i=SIZE -1 ; i>0; i--) {
        c = a[i-1]*2 ;
        a[i] = (c >0 ? c : 1);
    }
}
```

$$d = -(c^W - c^R) = -i + i - 1 = -1$$

```
a[SIZE-1] = a[SIZE-2]*2:1;
a[SIZE-2] = a[SIZE-3]*2:1;
```

*Write after read*

Código vectorizável!

# Bloqueadores Auto-vectorização: dependências

```
#define SIZE 1000000
float a[SIZE] __attribute__ ((aligned(32)));
loop () {
    for (int i=9 ; i< SIZE ; i++) {
        a[i] = a[i-9] + 1;
    }
}
```

Máquina AVX: largura das unidades funcionais W= 8

d = i - (i-9) = 9  
d>0 => RaW

Mas d>W ; 9 > 8

Código vectorizável

# Processamento Vectorial: Linhas de Orientação

- Usar ciclos “for” contáveis: pontos únicos de entrada e saída;
- Evitar estruturas condicionais; no entanto, máscaras são vectorizáveis;
- Evitar dependências, especialmente do tipo “read-after-write”
- Evitar a utilização de apontadores e prevenir *aliasing*
- Usar acessos à memória eficientes:
  - Ciclo mais aninhado com *stride* 1 (dados consecutivos)
  - Alinhar os dados a múltiplos de 32 (Intel® AVX)